

Raport projektowy: klasyfikacja obrazów pomieszczeń z wykorzystaniem sieci neuronowych

Michał Dyło, Agnieszka Wardak

25 czerwca 2026

1 Wstęp i opis zagadnienia

Celem projektu było zbudowanie i porównanie modeli głębokiego uczenia do klasyfikacji obrazów pomieszczeń. Rozważany problem należy do klasyfikacji wieloklasowej obrazów RGB: dla danego zdjęcia model ma wskazać typ pomieszczenia. W finalnej wersji eksperymentu rozpoznawano cztery klasy: `bed`, `din`, `kitchen` oraz `living`.

Zadanie jest trudniejsze niż klasyfikacja prostych obiektów, ponieważ klasy nie są definiowane przez pojedynczy charakterystyczny element. Sypialnia, salon i jadalnia mogą zawierać podobne meble, a granica między kuchnią i jadalnią bywa nieostra. Dodatkowo zdjęcia różnią się oświetleniem, perspektywą, stylem wnętrza, liczbą widocznych obiektów i stopniem uporządkowania sceny. Oznacza to, że model musi uczyć się zarówno lokalnych cech obrazu, jak i szerszego kontekstu przestrzennego.

Porównano trzy grupy modeli:

- MLP jako prosty model bazowy pracujący na spłaszczonych pikselach,
- własną sieć konwolucyjną typu ResNet trenowaną od zera bez augmentacji,
- tę samą rodzinę sieci konwolucyjnych trenowaną z augmentacją danych oraz wariant ensemble.

Ważnym założeniem było to, że modele CNN nie korzystają z transfer learningu ani gotowych wag. Sieci były trenowane od zera, dzięki czemu porównanie między zwykłym CNN a CNN z augmentacją dotyczy faktycznie wpływu procedury uczenia i przetwarzania danych, a nie użycia wcześniej wytrenowanego modelu.

2 Opis i eksploracyjna analiza danych

Wykorzystano zbiór *House Rooms & Streets Image Dataset* z Kaggle [1]. Dataset zawiera katalogi `house_data` oraz `street_data`; w projekcie użyto wyłącznie katalogu

house_data, ponieważ dotyczył zdjęć wnętrz.

W katalogu house_data znajdowało się 5249 obrazów w pięciu klasach. Etykieta była zapisana w nazwie pliku jako prefiks, np. bed_...jpg. Liczebności klas przedstawiono w tabeli 1.


Tabela 1: Liczebność klas w pełnym katalogu house_data.

Klasa	Liczba obrazów
bath	605
bed	1248
din	1158
kitchen	965
living	1273
Razem	5249

Klasę bath usunięto z finalnego eksperymentu, aby zachować zgodność z wcześniejszą wersją notebooka oraz skupić się na klasach o większej wzajemnej niejednoznaczności wizualnej. Po usunięciu tej klasy pozostały 4644 obrazy. Dane podzielono stratyfikacyjnie na zbiory treningowy, walidacyjny i testowy w proporcji 70%/15%/15%. Ten sam podział był używany dla wszystkich modeli, co umożliwia bezpośrednie porównanie wyników.

Tabela 2: Stratyfikowany podział danych po usunięciu klasy bath.

Podzbiór	bed	din	kitchen	living	Razem
Treningowy	873	811	675	891	3250
Walidacyjny	187	174	145	191	697
Testowy	188	173	145	191	697



Rysunek 1: Przykładowe obrazy z czterech klas użytych w eksperymencie.

Podczas eksploracji danych zauważono, że klasy są dość zbalansowane, ale nie idealnie. Najmniej przykładów ma klasa kitchen, a najwięcej living. Różnice nie są na tyle duże, aby wymagały agresywnego oversamplingu, natomiast w funkcji straty zastosowano wagi klas obliczone na podstawie liczebności zbioru treningowego. Dzięki temu błędy w mniej licznej klasie nie są marginalizowane.

Preprocessing był zależny od modelu:

- MLP używał obrazów 96×96 , ponieważ większe wejście znacznie zwiększa liczbę wag w pierwszej warstwie gęstej.
- Zwykły CNN bez augmentacji był oceniany dla najlepszego wariantu 224×224 .
- Najlepsze modele CNN z augmentacją używały obrazów 256×256 .

Dla wszystkich modeli obrazy konwertowano do RGB, skalowano do odpowiedniego rozmiaru i normalizowano przy użyciu średniej oraz odchylenia standardowego ImageNet:

$$\mu = (0.485, 0.456, 0.406), \quad \sigma = (0.229, 0.224, 0.225).$$

Normalizacja nie oznacza użycia transfer learningu; jest jedynie standardowym przeskalowaniem kanałów wejściowych.

3 Architektury sieci i procedura uczenia

3.1 Funkcja straty i metryki

Modele trenowano w PyTorch. Minimalizowaną funkcją straty była ważona entropia krzyżowa z label smoothing:

$$\mathcal{L}(x, y) = - \sum_{c=1}^C w_c \tilde{y}_c \log p_c,$$

gdzie w_c jest wagą klasy, p_c prawdopodobieństwem przewidywanym przez model, a $\tilde{y}$ wygładzoną etykietą. W modelach z MixUp/CutMix funkcja straty obsługiwała również miękkie etykiety.

Jako główne metryki raportowano accuracy oraz macro F1. Macro F1 jest szczególnie istotne, ponieważ liczy średnią jakość po klasach, a nie po przykładach, więc lepiej pokazuje, czy model działa równomiernie na wszystkich kategoriach.

3.2 Model bazowy MLP

MLP użyto jako punktu odniesienia. Model nie wykorzystuje lokalnej struktury obrazu, ponieważ po warstwie Flatten traktuje obraz jako jeden długi wektor pikseli. Architektura MLP była następująca:

Tabela 3: Architektura modelu MLP.

Element	Opis
Wejście	obraz RGB 96×96 , czyli 27648 cech po spłaszczeniu
Warstwa 1	Linear(27648, 1024) + BatchNorm + ReLU + Dropout(0.50)
Warstwa 2	Linear(1024, 512) + BatchNorm + ReLU + Dropout(0.50)
Warstwa 3	Linear(512, 256) + BatchNorm + ReLU + Dropout(0.375)
Wyjście	Linear(256, 4)

Najlepszy wariant MLP uzyskano dla rozmiaru obrazu 96×96 , learning rate $5 \cdot 10^{-4}$, weight decay 10^{-4} , dropout 0.50 i label smoothing 0.03. Model był trenowany z early stopping; najlepszy punkt walidacyjny wystąpił w 28. epoce.

3.3 Własna sieć CNN typu ResNet

Główny model konwolucyjny to własna architektura `RoomResNet`, trenowana od zera. Nie użyto gotowej sieci ani wag pretrenowanych. Architektura łączy bloki rezydualne, BatchNorm, aktywację SiLU, Squeeze-and-Excitation oraz global average pooling.

Pojedynczy blok rezydualny ma postać:

$$\begin{aligned}
 x &\rightarrow \text{Conv}_{3 \times 3} \rightarrow \text{BN} \rightarrow \text{SiLU} \rightarrow \text{Dropout2D} \\
 &\rightarrow \text{Conv}_{3 \times 3} \rightarrow \text{BN} \rightarrow \text{SE} \rightarrow +\text{shortcut} \rightarrow \text{SiLU}.
 \end{aligned}$$

Jeżeli liczba kanałów lub rozdzielczość zmienia się między wejściem i wyjściem bloku, shortcut zawiera konwolucję 1×1 ze stride.

Moduł Squeeze-and-Excitation [4] najpierw wykonuje global average pooling, następnie przechodzi przez dwie konwolucje 1×1 i funkcję sigmoid. W ten sposób model uczy się ważenia kanałów cech.

Tabela 4: Konfiguracje architektury `RoomResNet`.

Wariant	Kanały stem	Kanały etapów	Liczba bloków	Parametry
small	32	48, 96, 192, 320	2, 2, 2, 2	ok. 5.08 mln
medium	48	64, 128, 256, 384	2, 2, 3, 2	ok. 9.15 mln
large	64	80, 160, 320, 512	2, 3, 4, 2	ok. 17.63 mln

Finalnie najlepsze wyniki dawał wariant `large`. Jego dokładna struktura składa się z:

- dwóch konwolucji wejściowych 3×3 z 64 kanałami,
- czterech etapów rezydualnych o kanałach 80, 160, 320 i 512,
- liczby bloków w etapach równej odpowiednio 2, 3, 4 i 2,

- global average pooling do wektora 512,
- klasyfikatora Linear(512, 256) + SiLU + Dropout + Linear(256, 4).

Wariant CNN bez augmentacji był trenowany bez jakichkolwiek losowych modyfikacji obrazu. To ważne rozróżnienie: zwykły CNN miał służyć jako kontrola, a CNN+aug jako wariant pokazujący wpływ augmentacji i regularizacji danych.

3.4 CNN z augmentacją danych

Wariant CNN+aug używa tej samej rodziny architektur `RoomResNet`. Różni się procedurą treningową i przetwarzaniem danych. W profilu augmentacji `strong` zastosowano:

- `RandomResizedCrop` do rozmiaru wejściowego, skala 0.62–1.00, proporcje 0.80–1.25,
- losowe odbicie poziome,
- `ColorJitter` dla jasności, kontrastu, nasycenia i barwy,
- `RandAugment` z dwoma operacjami o sile 7,
- losową skalę szarości, autokontrast i zmianę ostrości,
- `GaussianBlur`,
- `RandomAffine` oraz `RandomPerspective`,
- `RandomErasing` po normalizacji.

Dodatkowo dla najlepszych modeli użyto `MixUp` [6] i `CutMix` [7]. `MixUp` tworzy wypukłą kombinację dwóch obrazów i ich etykiet, a `CutMix` wkleja fragment jednego obrazu do drugiego i miesza etykiety proporcjonalnie do pola wklejonego fragmentu. Najlepszy model CNN+aug używał:

$$\alpha_{\text{mixup}} = 0.2, \quad \alpha_{\text{cutmix}} = 1.0, \quad p_{\text{mix}} = 0.45.$$

W ocenie modeli CNN+aug zastosowano test-time augmentation (TTA). Dla każdego obrazu wykonano 5 predykcji: jedną deterministyczną oraz dodatkowe losowe cropy/odbicia, a następnie uśredniono prawdopodobieństwa. Zwykły CNN i MLP były oceniane bez TTA.

3.5 Procedura uczenia i strojenie hiperparametrów

Wszystkie modele trenowano z optymalizatorem `AdamW` [5]. Maksymalną liczbę epok ustawiono wysoko, ale trening kończono przez early stopping na podstawie macro F1 na zbiorze walidacyjnym. Dzięki temu modele mogły trenować długo, ale nie wybierano wag z końca uczenia, jeśli walidacja przestawała się poprawiać.

Strojenie hiperparametrów wykonano etapowo:

- dla MLP porównano warianty rozmiaru wejścia, learning rate, weight decay i dropout;
- dla zwykłego CNN przeszukano warianty `medium/large`, learning rate $3 \cdot 10^{-4}$ i $5 \cdot 10^{-4}$, weight decay $5 \cdot 10^{-4}$ i 10^{-3} , dropout 0.40 i 0.50;
- dla CNN+aug wykonano grid search po learning rate, weight decay, dropout i prawdopodobieństwie MixUp/CutMix.

Tabela 5: Najważniejsze hiperparametry najlepszego pojedynczego modelu CNN+aug.

Parametr	Wartość
Architektura	RoomResNet large
Rozmiar wejścia	256×256
Liczba parametrów	17.63 mln
Learning rate	$2 \cdot 10^{-4}$
Weight decay	$5 \cdot 10^{-4}$
Dropout w głowie	0.40
Label smoothing	0.10
Scheduler	cosine decay z 12 epokami warmup
EMA wag	0.999
MixUp/CutMix	$\alpha_{\text{mixup}} = 0.2$, $\alpha_{\text{cutmix}} = 1.0$, $p = 0.45$
TTA w ewaluacji	5 predykcji na obraz

Najlepszy pojedynczy model CNN+aug osiągnął najlepszy punkt walidacyjny w 206. epoce. W tym punkcie walidacyjne macro F1 wyniosło 0.8681, a accuracy 0.8694. Model trenowano łącznie 281 epok, po czym early stopping zatrzymał uczenie.

Oprócz pojedynczych modeli zbudowano ensemble trzech najlepszych modeli CNN+aug z grid searcha. Ensemble nie wymaga dodatkowego treningu: dla każdego obrazu liczone są prawdopodobieństwa trzech modeli, następnie są one uśredniane, a przewidywana klasa to argmax średniego wektora prawdopodobieństw. W ensemble użyto modeli:

- `lr2e4_wd5e4_d40_m45`,
- `lr3e4_wd5e4_d40_m30`,
- `lr2e4_wd5e4_d45_m45`.

4 Wyniki

Wyniki w tabeli 6 pochodzą z wykonanego notebooka ewaluacyjnego `evaluate_trained_models.ipynb`. Test obejmował 697 obrazów.

Tabela 6: Porównanie wyników na zbiorze testowym.

Model	Accuracy	Macro F1	TTA
MLP	40.89%	40.80%	1
CNN bez augmentacji	64.99%	65.23%	1
Najlepszy pojedynczy CNN+aug	88.81%	88.70%	5
Ensemble top 3 CNN+aug	89.81%	89.70%	5

Wyniki pokazują bardzo wyraźną różnicę między MLP a modelami konwolucyjnymi. MLP osiąga tylko 40.80% macro F1, ponieważ po spłaszczeniu obrazu traci informację o lokalnym sąsiedztwie pikseli. Zwykły CNN poprawia wynik do 65.23% macro F1, ale bardzo silnie przeucza się do zbioru treningowego. W jego historii treningowej accuracy treningowe dochodziło do prawie 100%, podczas gdy walidacja pozostawała w okolicach 65%.

Największy wzrost jakości daje augmentacja. Najlepszy pojedynczy model CNN+aug osiąga 88.70% macro F1, czyli ponad 23 punkty procentowe więcej niż zwykły CNN. Ensemble trzech modeli poprawia wynik do 89.70% macro F1.

4.1 Wyniki per klasa

Tabela 7: Metryki per klasa dla finalnego ensemble.


Klasa	Precision	Recall	F1	Support
bed	0.914	0.957	0.935	188
din	0.893	0.873	0.883	173
kitchen	0.868	0.910	0.889	145
living	0.911	0.853	0.881	191

Najłatwiejszą klasą dla finalnego modelu jest `bed`, dla której recall wynosi 95.7%. Najtrudniejsze pozostają `din` oraz `living`; są to klasy często współwystępujące wizualnie, np. w otwartych przestrzeniach typu salon z jadalnią.

4.2 Macierze pomyłek

Tabela 8: Macierz pomyłek finalnego ensemble. Wiersze oznaczają klasy prawdziwe, kolumny predykcje.

	bed	din	kitchen	living
bed	180	0	2	6
din	3	151	12	7
kitchen	2	8	132	3
living	12	10	6	163



Rysunek 2: Macierz pomyłek finalnego ensemble zapisana przez notebook ewaluacyjny.

Dla porównania, zwykły CNN bez augmentacji osiągał dużo niższy wynik i częściej mylił living z bed oraz din. Jego macierz pomyłek przedstawiono w tabeli 9.

Tabela 9: Macierz pomyłek najlepszego zwykłego CNN bez augmentacji.

	bed	din	kitchen	living
bed	135	9	10	34
din	14	107	17	35
kitchen	14	19	98	14
living	36	29	13	113

5 Podsumowanie

Projekt pokazuje, że dla klasyfikacji obrazów pomieszczeń sama architektura CNN nie wystarcza. Zwykły model konwolucyjny trenowany bez augmentacji uczy się zbioru treningowego bardzo dobrze, ale generalizuje ograniczenie. Wynik 65.23% macro F1 wskazuje na silne przeuczenie.

Największą poprawę uzyskano przez połączenie kilku elementów: mocniejszej architektury rezydualnej, dużej rozdzielczości wejścia, silnej augmentacji, MixUp/CutMix, EMA wag, schedulera cosine z warmupem oraz TTA w ewaluacji. Najlepszy pojedynczy model CNN+aug osiągnął 88.70% macro F1, a ensemble trzech modeli poprawił wynik do 89.70% macro F1.

Najważniejsze wnioski:

- MLP jest zbyt słaby dla tego zadania, ponieważ ignoruje przestrzenną strukturę obrazu.
- CNN bez augmentacji wyraźnie przewyższa MLP, ale nadal przeucza się do danych treningowych.
- Augmentacja jest kluczowym składnikiem rozwiązania; odpowiada za największy wzrost jakości.
- Ensemble daje dodatkową, mniejszą, ale stabilną poprawę względem najlepszego pojedynczego modelu.
- Najtrudniejsze pomyłki dotyczą klas semantycznie podobnych, zwłaszcza `din`, `kitchen` i `living`.

Dalszą poprawę można byłoby uzyskać przez ręczne przejrzanie błędnie sklasyfikowanych obrazów, dodatkową kalibrację ensemble oraz ewentualne wykorzystanie większej liczby seedów. W projekcie świadomie nie zastosowano transfer learningu; jego użycie prawdopodobnie mogłoby podnieść wynik, ale zmieniłoby charakter porównania.

Literatura

- [1] Mikhail Ma, *House Rooms & Streets Image Dataset*, Kaggle. <https://www.kaggle.com/datasets/mikhailma/house-rooms-streets-image-dataset>
- [2] Paszke, A. et al., *PyTorch: An Imperative Style, High-Performance Deep Learning Library*, NeurIPS, 2019.
- [3] He, K., Zhang, X., Ren, S., Sun, J., *Deep Residual Learning for Image Recognition*, CVPR, 2016.
- [4] Hu, J., Shen, L., Sun, G., *Squeeze-and-Excitation Networks*, CVPR, 2018.
- [5] Loshchilov, I., Hutter, F., *Decoupled Weight Decay Regularization*, ICLR, 2019.

- [6] Zhang, H. et al., *mixup: Beyond Empirical Risk Minimization*, ICLR, 2018.
- [7] Yun, S. et al., *CutMix: Regularization Strategy to Train Strong Classifiers with Localizable Features*, ICCV, 2019.
- [8] Cubuk, E. D. et al., *RandAugment: Practical Automated Data Augmentation with a Reduced Search Space*, CVPR Workshops, 2020.