

Raport projektowy: klasyfikacja obrazów pomieszczeń przy użyciu głębokich sieci neuronowych

Michał Dyło, Agnieszka Wardak

24 czerwca 2026

1 Wprowadzenie i opis zagadnienia

Celem projektu jest zbudowanie modelu klasyfikującego zdjęcia pomieszczeń na podstawie obrazu RGB. Zadanie należy do obszaru widzenia maszynowego, ale jest trudniejsze niż prosta klasyfikacja pojedynczych obiektów, ponieważ klasy pomieszczeń mają wysoką wariancję wewnątrzklasową. Ta sama kategoria może występować pod wieloma kątami, w różnym oświetleniu i z różnym układem mebli. Dodatkowo pomieszczenia dzielą wiele elementów wizualnych: stół może pojawić się w jadalni, kuchni i salonie, a nowoczesne wnętrza często łączą funkcje kilku pomieszczeń.

W projekcie porównano trzy podejścia o rosnącej zdolności modelowania struktury obrazu:

- wielowarstwowy perceptron MLP jako model bazowy,
- sieć konwolucyjną CNN,
- sieć CNN trenowaną z augmentacją danych.


Wszystkie obrazy zostały przeskalowane do rozmiaru 64×64 pikseli. Tak mała rozdzielczość ogranicza koszt obliczeniowy, ale utrudnia klasyfikację, ponieważ część detali wyposażenia zostaje utracona.

2 Opis i eksploracyjna analiza danych

Wykorzystano zbiór *House Rooms & Streets Image Dataset* z Kaggle [1]. Dataset zawiera dwa katalogi: `house_data` oraz `street_data`. W projekcie użyto wyłącznie katalogu `house_data`, który zawiera zdjęcia wnętrz w pięciu klasach: `bath`, `bed`, `din`, `kitchen`, `living`.

Tabela 1: Liczebność klas w katalogu house_data.

Klasa	Liczba obrazów
bath	605
bed	1248
din	1158
kitchen	965
living	1273
Razem	5249




Rysunek 1: Rozkład liczby zdjęć w klasach przed usunięciem klasy bath.

Oryginalne obrazy mają rozdzielczość 224×224 pikseli. Po analizie liczebności odrzucono klasę bath. Po tej operacji problem sprowadzono do klasyfikacji czterech klas: bed, din, kitchen, living. Liczba obrazów użytych w treningu wyniosła 4644.

Tabela 2: Podział danych po usunięciu klasy bath.

Podzbiór	Udział	Liczba obrazów
Treningowy	70%	3250
Walidacyjny	15%	697
Testowy	15%	697



Rysunek 2: Przykładowe obrazy z klas użytych w notebooku.

Preprocessing obejmował:

- wczytanie plików .jpg,
- wyodrębnienie etykiety z prefiksu nazwy pliku,
- przeskalowanie obrazu do 64×64 ,
- konwersję do tensora Float32,
- zmianę układu kanałów do formatu (wysokosc, szerokosc, kanaly, batch),
- kodowanie etykiet w reprezentacji one-hot.

3 Architektury sieci i procedura uczenia

Do trenowania modeli użyto biblioteki Flux.jl. Minimalizowaną funkcją straty była entropia krzyżowa dla logitów:

$$\mathcal{L}(y, \hat{z}) = - \sum_i y_i \log(\text{softmax}(\hat{z})_i),$$

gdzie y oznacza prawdziwą etykietę w formacie one-hot, a $\hat{z}$ oznacza logity modelu. W warstwach ukrytych stosowano aktywację ReLU:

$$\text{ReLU}(x) = \max(0, x).$$


3.1 Model 1: MLP

Model MLP potraktowano jako baseline. Obraz $64 \times 64 \times 3$ został spłaszczony do wektora o długości 12288. Przetestowano trzy topologie:

Tabela 3: Topologie MLP.

Topologia	Architektura
1	Flatten → Dense(12288, 512) → Dropout → Dense(512, 4)
2	Flatten → Dense(12288, 256) → Dropout → Dense(256, 64) → Dropout → Dense(64, 4)
3	Flatten → Dense(12288, 128) → Dropout → Dense(128, 64) → Dense(64, 32) → Dense(32, 4)

Dla MLP przeszukano batch size $\{32, 64\}$, learning rate $\{0.001, 0.0005, 0.0001\}$, dropout 0.3 oraz trzy topologie. Najlepszy wynik walidacyjny uzyskała topologia 1 dla batch size 32, learning rate 0.0001 i dropout 0.3.



Rysunek 3: Krzywe straty i accuracy dla najlepszego MLP z grid search.


3.2 Model 2: CNN

Drugi model wykorzystywał warstwy konwolucyjne, które zachowują lokalną strukturę obrazu. Przetestowano trzy topologie CNN:

Tabela 4: Topologie CNN.

Topologia	Architektura
1	Conv(3x3, 16) → MaxPool → Conv(3x3, 32) → MaxPool → Conv(3x3, 64) → MaxPool → Dense(128) → Dense(4)
2	Conv(3x3, 16) → Conv(3x3, 16) → MaxPool → Conv(3x3, 32) → Conv(3x3, 32) → MaxPool → Dense(256) → Dense(4)
3	Conv(5x5, 16) → MaxPool → Conv(3x3, 32) → MaxPool → Dense(64) → Dense(4)

Dla CNN przeszukano batch size $\{32, 64\}$, learning rate $\{0.001, 0.0005\}$, dropout $\{0.3, 0.5\}$ oraz trzy topologie. Najlepszy wynik walidacyjny uzyskała topologia 2 dla batch size 32, learning rate 0.001 i dropout 0.3.




Rysunek 4: Krzywe straty i accuracy dla ostatecznego CNN z early stopping.

3.3 Model 3: CNN z augmentacją danych

Trzeci wariant wykorzystał najlepszą architekturę CNN i dodał augmentację danych wykonywaną w locie. Zastosowano:

- losowe odbicie lustrzane w poziomie z prawdopodobieństwem 50%,
- losową zmianę jasności w zakresie 80–120%,
- losowe przesunięcie obrazu maksymalnie o 4 piksele.

Wariant z augmentacją trenowano maksymalnie przez 50 epok z cierpliwością early stopping równą 7. Najlepszy wynik walidacyjny wystąpił w 23. epoce i wyniósł 66.57%.



Rysunek 5: Krzywe straty i accuracy dla CNN z augmentacją.

4 Wyniki

Tabela 5: Porównanie głównych wyników.

Model	Najlepsze accuracy walidacyjne	Accuracy testowe
MLP, grid search	39.45%	39.60%
CNN, grid search	54.81%	55.52%
CNN + augmentacja	66.57%	63.56%

Wyniki pokazują wyraźny wzrost jakości po przejściu z MLP na CNN. MLP traci informację o lokalnej strukturze pikseli po spłaszczeniu obrazu, co ogranicza jego skuteczność. CNN poprawia wynik testowy o około 16 punktów procentowych, a augmentacja dodaje kolejne około 8 punktów procentowych względem najlepszego CNN z grid search.

4.1 Macierze pomyłek

Tabela 6: Macierz pomyłek MLP. Wiersze: predykcja, kolumny: prawdziwa klasa.

	bed	din	kitchen	living
bed	98	60	30	52
din	48	96	51	42
kitchen	6	11	24	19
living	35	32	35	58

Tabela 7: Macierz pomyłek CNN. Wiersze: predykcja, kolumny: prawdziwa klasa.

	bed	din	kitchen	living
bed	96	9	22	29
din	21	155	42	50
kitchen	32	12	61	17
living	38	23	15	75

Tabela 8: Macierz pomyłek CNN z augmentacją. Wiersze: predykcja, kolumny: prawdziwa klasa.

	bed	din	kitchen	living
bed	122	10	19	23
din	12	135	27	27
kitchen	26	19	84	19
living	27	35	10	102

4.2 Precision i recall

Tabela 9: Metryki per klasa dla najlepszego wariantu CNN z augmentacją.

Klasa	Precision	Recall
bed	70.11%	65.24%
din	67.16%	67.84%
kitchen	56.76%	60.00%
living	58.62%	59.65%

Najłatwiejsze do rozpoznania były klasy `bed` i `din`. Najsłabsze wyniki dotyczą `kitchen` i `living`, co jest zgodne z intuicją: kuchnie, jadalnie i salony często współdzielą podobne elementy wizualne oraz układ przestrzenny.

5 Podsumowanie

Eksperyment potwierdził, że dla obrazów wnętrz istotne jest zachowanie informacji przestrzennej. MLP, mimo strojenia hiperparametrów, osiągnął tylko 39.60% accuracy na zbiorze testowym. Zastosowanie warstw konwolucyjnych zwiększyło wynik do 55.52%, a augmentacja danych poprawiła generalizację do 63.56%.

Najlepszym modelem w przeprowadzonym eksperymencie był CNN z augmentacją. Wynik nie jest idealny, ale jest uzasadniony trudnością danych: klasy są podobne, ob-

razy mają niską rozdzielczość wejściową, a model nie korzysta z transfer learningu. Dalsze ulepszenia powinny obejmować:

- użycie transfer learningu, np. modelu wstępnie trenowanego na ImageNet,
- stratified split, aby zachować proporcje klas w każdym podzbiorze,
- zapis konfiguracji i wyników eksperymentów do plików,
- poprawę augmentacji przesunięć tak, aby nie zawijać pikseli przez `circshift`,
- rozważenie pozostawienia klasy `bath` i użycia wag klas zamiast usuwania klasy.

Literatura

- [1] Mike Mazurov, *House Rooms & Streets Image Dataset*, Kaggle, 2022. <https://www.kaggle.com/datasets/mikhailma/house-rooms-streets-image-dataset>
- [2] Flux.jl documentation. <https://fluxml.ai/Flux.jl/stable/>
- [3] Ian Goodfellow, Yoshua Bengio, Aaron Courville, *Deep Learning*, MIT Press, 2016. <https://www.deeplearningbook.org/>